AgentForge 企业技术方案

控制面现状 · 领域模型 · 流程 · 模块 · 实现 · AgentScope 企业实战 · 2026-09-23

这套系统是企业 Agent 的控制面：人、租户、模型、工具、知识库、记忆和评测都在 Spring Boot 里管理。一轮推理交给 AgentScope Java 2.0.3 的 ReActAgent。工具仍由控制面执行，身份不会丢在模型线程上。

1. 分层



层	技术	职责
控制台	静态 `app.js`，端口 8080	概览、会话、调试台、知识库、记忆、评测、权限
接口	Spring MVC + AuthInterceptor	登录、试用、权限、租户切换
领域	JPA，MySQL，ddl-auto=none	配置、会话、知识库状态、记忆、评测
推理	AgentScope 2.0.3，Java 21	ReAct 循环、OpenAI 兼容模型
存储	MySQL、rag-files/、workspaces/、Milvus	结构化数据、原文、检查点、向量

> HTTP 请求把登录用户放进 CurrentUserHolder。generate 捕获这个用户，每次工具调用再用 CurrentUserHolder.call 包回去。知识库和记忆都读这个身份。

2. 领域模型

业务对象多数继承 TenantOwnedEntity：`tenant_id` 必填，`owner_id` 是属主。平台管理员可以用请求头切换当前租户，账号所属租户单独保留。

2.1 身份

对象	键	含义
Tenant / User / Role	租户 + 角色权限	组织边界。权限按 OR 判断，write 隐含 read
AuthToken	bearer；试用另有 trial_key	登录会话。试用 5 分钟，cookie `af_trial` 粘在浏览器上
subject_key	`user:{id}` 或 `trial:{凭证}`	记忆和会话的主人。试用不能共用 guest 的用户 id

2.2 Agent 聚合

绑定	运行时
model_name → purpose=chat	调试台只用 Agent 上的模型，不接受临时切换
skill_ids / mcp_ids	写进系统提示词，并注册为工具
knowledge_ids	检索范围还要和当前用户能看见的库取交集
http_agent_ids	整段对话转发到外部平台，不走本机工具和记忆总结
sandbox_id / tool_flows	沙箱执行代码，或把多步工具收成一个 flow 工具

2.3 知识、记忆、会话

实体	存放	边界
KnowledgeBase / Member / Document	配置和状态在 MySQL，原文在磁盘，分块在 Milvus	默认私有。tenant 可见只扩大检索，不自动获得编辑权
Conversation / ChatMessage	MySQL	短期记忆。只在本会话内，窗口为最近 20 条或约 6000 字
MemoryItem	MySQL，软删除	长期记忆。此人在该租户下各 Agent 共用。对话结束后自动总结
Trace	MySQL 和工作区	步骤名是「调用工具 xxx」，没有单独的 RAG 节点
VisitorDay	MySQL	概览访问次数。每次打开加 1，不去重到人
Dataset / Evaluation / Experiment	MySQL	回归测试和 A/B 分流，不写入长期记忆

---

3. 流程

3.1 一轮对话



回复成功并且模式是 ready 之后，MemorySummarizer 再用同一个对话模型看本轮用户话和助手回复，只把稳定事实写入 memory_items。闲聊、一次性问题和文档摘录不写入。相同正文不重复记。总结失败不影响已经返回的回复。

3.2 知识库

上传后清洗，按文档形态自动选择分块。子块做稠密向量和 BM25，混合检索用 RRF。若配置了 rerank 模型，再打分截断。返回给模型的是所在章节 context，最长约 2000 字。权限不进向量：每次用「Agent 绑定的库 ∩ 当前用户可见的库」过滤。交集为空时，工具只说当前没有可检索的文档。

3.3 模型用途

purpose	协议	约束
chat	OpenAI 兼容 /chat/completions	没有密钥时只给预览回复
embedding	POST /embeddings，input 为字符串数组	不能把对话模型指到这个地址
rerank	POST /rerank	调用失败则本次检索失败，不退回纯 RRF

4. 模块职责

包	功能	改行为时先看
access	登录、试用、权限、工具线程身份	AuthService、CurrentUserHolder、ResourceAccessService
web	控制台的 REST	PlaygroundController、KnowledgeController、MemoryController
agent	ReAct、工具、外部 HTTP Agent、链路	AgentScopeRuntime、ToolRuntime
rag	清洗、分块、Milvus、重排序、库权限	KnowledgeIndexService、KnowledgeSearchService
memory	会话窗口和对话后总结	MemoryService、MemorySummarizer
playground	调试台落库和 Trace	PlaygroundService
eval / experiment	回归和 A/B	EvalService、ExperimentService
runtime	沙箱、浏览器、OpenCLI	SandboxRuntime、BrowserRuntime
config	补表、把 SQLAlchemy URL 转成 JDBC	SchemaMigrator

5. 实现方案

- 基础表不由本仓库创建。SchemaMigrator 只增加后续表和列。
- ReAct 默认最多 4 轮；带浏览器或 OpenCLI 时 8 轮。检查点失败可以续跑，续跑沿用检查点里的 working，不重新截断。
- 系统提示词顺序：人设、Skill、可用工具说明、编排提示、知识库提示、长期记忆。
- 新增企业工具只加在 ToolRuntime：声明 schema，在 executeTool 执行，身份从 CurrentUserHolder 取。工具参数不接收用户 id 或租户 id。
- 静态页改完后提高 index.html 里的脚本版本，否则浏览器继续用旧文件。

> 管理员可以在管理界面看到知识库以便排障，但不能借此检索别人的私有文档，也不能在记忆页看到别人的事实。

---

6. AgentScope 企业实战

AgentScope 在这里只做推理循环和模型协议。企业规则放在控制面。按下面顺序做一条生产助手，比先写一个大提示词更稳。

6.1 模型与 Agent

先建三个用途的模型：对话、向量、重排序。Agent 的 model_name 只指向对话模型。调试台不再提供临时模型下拉，避免空密钥或评测密钥进入生产对话。

6.2 工具

Skill 写必须遵守的业务流程。需要查时间、跑代码、调外部系统时，做成 MCP、沙箱或控制面工具，由模型决定是否调用。注册进 Toolkit 的是名字和参数；执行仍回到 ToolRuntime，这样能打到当前登录人。

6.3 知识库

全员制度用租户公开。私人材料保持 private，协作时再加 viewer 或 editor。Agent 可以绑多个库。两个员工用同一个 Agent，各自只能搜到自己看得见的库。命中用子块，回答用章节。

6.4 记忆

会话内的上文自动带上。跨会话只保留总结出来的稳定事实：偏好、称呼、决定、更正。用户在记忆页改正或删除。评测用例不写入长期记忆。

6.5 上线

用数据测试准备问句和期望。评测每题一个新会话，走同一套 AgentScope 运行时。两个版本要用 A/B 实验分流，实验必须处于进行中。出问题看执行链路里的「调用工具」步骤和 Trace，而不是找一个叫 RAG 的节点。

6.6 验收一条路径

1. 管理员建私有知识库，上传制度，绑到个人助手。
2. 另一个账号用同一 Agent 提问，检索应为空，回答里也不出现库名。
3. 属主提问，链路里应出现 search_documents，回答依据章节原文。
4. 属主说「以后先给结论」。刷新记忆页，应出现自动总结，另一个账号看不到。