GraphRAG 深入浅出

给要选型、讲解或落地知识库的人 · 结合 AgentForge 知识库里的检索方式

GraphRAG 是在普通文档检索之外，先把文本里的人、事、组织、条款抽成「谁和谁有什么关系」，再按这些关系或整篇摘要来回答。找某一句话时，混合检索往往够用；问关系、问全貌时，图更合适。

> **30 秒版本：**普通 RAG 像在一摞资料里用荧光笔标出最像的几段。GraphRAG 先把资料整理成一张关系网，再准备每份文档的短摘要。问题点名了某个对象，就沿着它的关系回答；问题在问整体，就读这些摘要。

1. 为什么相似段落不够
2. GraphRAG 在做什么
3. 建库和查询的两段路
4. 导入流程
5. 查询流程
6. 和混合检索、传统知识图谱怎么分工
7. 六个常用场景
8. 在本知识库里怎么选
9. 落地时要守住的边界

一、为什么相似段落不够

常见知识库的做法是：文档切成小块，每块变成向量，再配上关键词。用户提问后，系统找出最像的几块，交给大模型组织成答案。问「年假几天」「第三条怎么写」，这种做法很稳，因为答案就躺在某一段里。

换一种问法，相似段落就开始吃力：

- 「这份供应商制度里，采购、法务、财务各自卡在哪一环？」答案散在不同章节，单段相似度都不高。
- 「A 产品和 B 组件是什么关系？故障会传到谁？」需要的是关系，不是某一句原文。
- 「这 20 份周报整体在推进什么、卡在哪里？」没有任何一块能代表全部文档。

GraphRAG 针对的就是后一类问题：先把散落的事实收成结构，再检索结构。

二、GraphRAG 在做什么

名字拆开就是 Graph（图）+ RAG（检索增强生成）。图上的点是实体，例如人、公司、产品、制度条款、系统模块；边是关系，例如「负责」「依赖」「引用」「属于」。检索时可以沿边走，也可以先读预先写好的摘要。

业界常被引用的做法来自微软 2024 年的 GraphRAG：用大模型从文本抽取实体和关系，再把联系紧密的实体收成一层层「社区」，给每个社区写摘要。问局部事实时钻到相关实体；问全局主题时读社区摘要，而不是把所有原文塞进一次对话。

可以把它想成两份索引，建在同一批文档上：

- **段落索引：**方便定位原文、数字、原句。
- **关系索引：**方便回答「谁连着谁」和「这批材料在讲什么」。

三、建库和查询的两段路

建库发生在上传之后，查询发生在用户提问时。把建图放到上传阶段，是为了让每次提问只做检索，避免每次都重新读完全文。

1. **清洗分块**
   去掉噪声，按标题、段落或条款切开。这一步和普通知识库相同。
2. **抽取**
   对话模型读每个分块，输出实体（名称、类型、描述）和关系（起点、终点、说明）。
3. **合并**
   同名实体合成一个点，保留更完整的描述。重复关系去掉。
4. **摘要**
   用实体和关系写一份短摘要，作为这份文档的「社区说明」。

局部查询

问题里出现了图上的名字，就走局部查询。例如文档里有实体「年假」，用户问「年假和入职多久有关」。系统找到「年假」，带上与它相连的边（「年假 → 入职满一年：方可申请」），把这些文字交给模型。回答贴近具体对象，证据是关系和描述，方便核对。

全局查询

问题里没有点名任何实体，或点名的名字不在图上，就走全局查询。系统改读各文档摘要，用来回答「这批制度整体在规范什么」「这几份纪要的共同主题是什么」。摘要在建库时已经写好，查询时只是挑选和拼接，成本远低于现场重读全文。

> 微软论文里的「社区」是用社区发现算法（如 Leiden）把整张大图切成多层团块，每层都有摘要。下面两节写的是本知识库当前的做法：一份文档就是一个社区，摘要就是这篇文档的关系概览。

四、导入流程

导入从「新建知识库并选 GraphRAG」开始，到这份文档变成 `ready` 结束。建图发生在上传之后的索引任务里，查询时不再调用图谱模型。

1. **选定检索方式。**新建知识库时，向量模型照常要选。检索方式选 GraphRAG，并指定一个本租户已启用的对话模型作为图谱模型。没选图谱模型，创建会被拒绝。已有库默认仍是混合检索，可在设置里改过来；一改方式或更换图谱模型，已有文档会重新排队处理。写入 knowledge_bases.retrieval_mode、graph_model_id
2. **上传原文件。**支持 txt、md、html、csv、docx、pdf。单次最多 10 个，单个不超过 15MB。文件落到 `rag-files`，文档先记为排队，再交给单线程索引队列。状态 queued → 索引线程
3. **抽出正文并清洗。**按文件类型取可复制文字，去掉噪声。清洗后不足 20 个字，文档失败，提示换成可复制文字的文件。扫描版 PDF 若抽不出字，会停在这一步。状态 processing
4. **分块。**按标题、段落、条款等自动选策略，也可以在重建时指定策略。没有可写入的分块，文档失败。分块结果同时供后面的向量和建图使用。
5. **能跳过就跳过。**正文哈希、向量模型、分块策略、向量库都没变，而且这份文档已经有与当前版本号一致的图，就直接标成就绪，不再调模型。换了图谱模型或强制重建时，这一步不跳过。
6. **写入向量库。**全部分块用向量模型嵌入，写入该租户、该知识库的 Milvus collection，并删掉这份文档更旧的版本。维度和库里已有维度不一致则失败。GraphRAG 库仍保留这段段落索引，供以后切回混合检索，或供长文档靠后的章节留在向量里。Milvus 分块

7. **逐块抽取实体和关系。**只取前 16 个分块。每块调用一次图谱模型，要求只返回 JSON：实体含名称、类型、描述，关系含起点、终点、说明，每类最多 8 条。能解析出内容的块才保留。同名实体合并成一个，留下描述更完整的那条；重复关系去掉，关系总数不超过 80。一个实体都没有，文档失败。图谱模型 /chat/completions，temperature 0
8. **写文档摘要。**把合并后的实体和关系再交给图谱模型，概括这篇文档的主题和关键关系。模型没有返回文字时，用实体描述拼一份兜底摘要。
9. **落库并就绪。**每个文档一行图：知识库、文档、版本号、摘要、实体 JSON、关系 JSON。文档状态改为就绪，并记下分块数、内容哈希和版本号。之后查询只读这行图，不再读原文件。表 kg_document_graphs，状态 ready

导入停在哪里	页面上看到什么
正文太短、分块为空、向量模型或 Milvus 不可用	文档失败，说明里是对应原因
图谱模型未启用、没有密钥，或调用失败	文档失败，说明里是图谱模型错误
16 个分块都没抽出实体	文档失败：「没有从文档里抽出实体」
上面都通过	状态就绪。调试检索可以开始用

五、查询流程

查询有两个入口，读的是同一张图。知识库页面的「调试检索」只查当前这一个库。智能体绑定知识库后，通过工具 `search_documents` 查它有权访问、且已启用的库；一个智能体绑了多个库时，每个库按自己的检索方式走，再把命中合在一起。

1. **只使用已就绪的文档。**状态不是 ready 的文档不参与。该库一份就绪文档都没有，调试检索返回空命中；智能体侧得到「没有足够相关的内容」。
2. **清洗问题。**问句走和导入相同的文本清洗。清洗后若是空白，就用去掉首尾空白的原问句。这一步只整理文字，不调用模型。
3. **确认这条库走图。**检索方式是 GraphRAG 时，这次查询不嵌入问题、不查 Milvus、也不做重排序。方式是混合检索的库，仍走向量加关键词。
4. **读出该库全部文档图。**一次取出实体、关系和摘要。图存在 MySQL，按文档一行。
5. **先尝试局部查询。**实体名至少两个字，并且问题里包含这个名字，或实体名包含整句问题，算命中。命中后带上类型、描述，以及它作为起点或终点的关系，形如「差旅 → 部门负责人：出差前审批」。局部命中最多 8 条。只要有一条局部命中，就不再读摘要。调试里显示 graphrag-local
6. **没有点名实体时走全局查询。**按文档取已写好的摘要，最多 6 份，标题记为「社区摘要」。用来回答「这批材料整体在说什么」。摘要是导入时生成的，查询当场不再让模型重写。调试里显示 graphrag-global
7. **按入口交出去。**调试检索按该库的返回条数（1 到 10）截断，重排序显示为 none，页面能看到文件名、实体名或「社区摘要」、描述和关系。智能体路径把各库命中放在一起：局部命中排在全局摘要前面，最多留 10 条，格式是「【序号】库名 / 文件名 / 标题」加下面的证据文字。
8. **由对话模型组织答案。**图查询到此结束。智能体拿到上述证据后，再按自己的系统提示作答。知识库没有命中时，应说明不知道，而不是用常识补全这些事实。

问法	走哪一步	返回里有什么
「部门负责人在差旅里做什么」	第 5 步，局部	实体「部门负责人」或「差旅」，以及相连的审批、报销关系
「这些制度整体在管什么」	第 6 步，全局	最多 6 份文档摘要，标题为社区摘要
问题里的名字和抽取时的名字对不上	局部落空，改走全局	摘要。要把全称和简称写进正文，查询才容易点中实体

六、和混合检索、传统知识图谱怎么分工

	混合检索	GraphRAG	人工搭建的知识图谱
索引里有什么	文本块的向量和关键词	实体、关系，外加文档摘要	预先定义好的本体和三元组
谁来生产结构	切块和向量模型	对话模型从正文里抽取	领域专家和数据工程师
问一句原文、一个数字	直接命中所在段落	能回到相关实体，原句不一定完整	取决于图里是否录入了该字段
问关系和全貌	靠多段拼接，容易漏跨章节的联系	沿边或读摘要	查询最稳，前提是图已经建全
更新一份新文档	重新切块、重新向量化	再抽取一遍该文档的图和摘要	按规范补点、补边，通常更慢
主要成本	向量模型，查询便宜	建库时多次调用对话模型	人力建模和持续维护

三种可以同时存在。混合检索负责「把原句找出来」，GraphRAG 负责「把关系和图景找出来」，人工图谱负责「必须严格、可审计的那部分关系」。

七、六个常用场景

场景 1 · 制度、合同、招投标文件

材料长、章节互相引用。用户很少问「第 12 页有没有出现违约」，更多问「违约后谁通知谁、保证金和验收是什么关系」。

实体可以是主体（甲方、供应商）、对象（保证金、验收）、动作（通知、扣除）。关系把流程串起来。局部查询回答某一个主体的义务；全局查询回答「这份合同整体在约束什么」。

仍建议保留混合检索，用来核对金额、日期和原条款措辞。

场景 2 · 研报、行业材料和竞品档案

一篇研报里公司、产品、客户、供应链缠在一起。分析师的问题常常是「这家公司和哪几家供应商绑在一起」，或「这批材料对某个赛道的共同判断是什么」。

图适合第一种；文档摘要适合第二种。若只要摘录某一段预测数字，混合检索更直接。

场景 3 · 故障手册和系统依赖

运维文档里真正有用的是依赖：服务 A 调用 B，B 依赖数据库 C，告警从 C 传到值班组。用户描述一个现象时，点名了服务名就能沿边看到上下游，而不是只命中某一段排障步骤。

适合组件名稳定、文档会反复提到同一批系统的知识库。

场景 4 · 会议纪要和项目周报

单份纪要里的待办，用关键词就能搜到。跨很多份纪要问「这个项目现在卡在哪个依赖、涉及哪些人」，需要把反复出现的项目、负责人和阻塞项收成点，再看边。

全局查询还能先给一个「最近这些纪要在重复什么主题」的概览，再让人点进某一份原文。

场景 5 · 产品说明和客服知识

FAQ 适合混合检索：「怎么重置密码」几乎总有标准答案段。GraphRAG 更适合功能之间的依赖：「开通高级版之后，哪些接口、哪些角色、哪份合同条款会一起变化。」

客服场景里建议两种都在：标准问句走混合检索，牵涉多个功能的问题走图。

场景 6 · 人物、组织和项目归属

内部百科、项目空间说明、组织材料里，高频问题是归属和协作：「这个项目归哪个组、和哪个系统有关、接口人是谁。」实体名短、重复出现，图的命中很直观。

人名和项目名要写全。抽取模型看到的是正文，正文里只写简称时，查询也要用同一个简称。

八、在本知识库里怎么选

新建知识库时，检索方式有两项。混合检索是向量加关键词，可选重排序，适合原句、数字、条款和 FAQ。GraphRAG 要再指定图谱模型，适合关系和文档全貌。导入怎么一步步落库，见第四节；提问之后怎么分流，见第五节。

已有知识库保持混合检索。设置里可以改方式。改成 GraphRAG 或更换图谱模型后，已有文档会按第四节重新处理。改回混合检索后，查询改走向量和关键词，已建的图会清掉。

> **走一遍。**一份《差旅制度》抽取出实体「差旅」「部门负责人」「报销」，关系是「差旅 → 部门负责人：出差前审批」「差旅 → 报销：返回后五个工作日内提交」。
>
> 问「部门负责人在差旅里做什么」，局部查询带回审批那条边。问「这份制度和别的财务材料都在管什么」，若问题里没有命中实体名，就读各文档摘要。

九、落地时要守住的边界

- **建库更慢，也更贵。**每个被抽样的分块都要调用一次对话模型，整篇还要一次摘要。混合检索主要消耗向量模型。文档很多时，先在一小批上确认抽取质量，再铺开。
- **抽取会漏，也会说多。**模型可能漏掉正文里的关系，或把猜测写成关系。回答时应能看到实体描述和关系原文，重要结论回到混合检索或原文件核对。
- **名字要对得上。**当前局部查询按名称包含来匹配，没有单独的实体向量。正文和用户用同一个叫法时最稳。别名很多的领域，要在文档里把全称和简称写在一起。
- **图要跟着文档走。**文件更新后要重建该文档的图。只改了图谱模型，也要重建，否则摘要仍是旧模型写的。
- **抽样有上限。**当前实现每个文档最多用前 16 个分块建图。短制度、说明、纪要很合适；特别长的单文件，靠前的章节会进入图，靠后的章节仍在向量库里，通过混合检索更能被逐段找到。
- **社区目前是「一篇文档一份摘要」。**它可以回答单文档主题，以及跨文档时把多份摘要放在一起看。若语料大到需要「先按主题团成多层社区再逐层汇总」，那是微软论文中的完整 GraphRAG，需要额外的社区发现和多层摘要，超出当前知识库这一档。

怎么向同事讲

混合检索负责把原句找准。GraphRAG 负责两件原句不擅长的事：沿着人、系统、条款之间的关系回答，以及用建库时写好的摘要回答「这批文档整体在说什么」。新建知识库时按问题类型选一种；两种都需要时，可以建两个库，或在设置里按当前材料切换。标准问句和精确数字，优先混合检索；关系和全貌，优先 GraphRAG。

参考：Darren Edge 等，*From Local to Global: A Graph RAG Approach to Query–Focused Summarization*（Microsoft Research，2024）。本文后半的检索方式、16 个分块、局部/全局分支，对应 AgentForge 知识库当前实现。